

## 第四章 朴素贝叶斯法

- 朴素贝叶斯法是基于贝叶斯定理与特征条件独立假设的分类方法。
- 朴素贝叶斯法与贝叶斯估计不同。

### 4.1 朴素贝叶斯法的学习和分类

#### 4.1.1 基本方法

- 输入:  $\mathcal{X} \subseteq R^n$  为  $n$  维向量集合
- 输出:  $\mathcal{Y} = \{c_1, c_2, \dots, c_k\}$ , 输出为类标记,  $y \in \mathcal{Y}$
- 数据集:  $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$  由  $P(X, Y)$  独立同分布产生。
- 训练过程: 通过训练数据集, 学习  $P(X, Y)$  (联合分布概率), 也就是分别学习先验概率分布  $P(Y = c_k), k = 1, 2, 3 \dots k$  和条件概率分布  $P(X = x|y = c_k) = P(X^{(1)} = x^{(1)}, \dots, X^{(n)} = x^{(n)}|Y = c_k)$ 
  - 但是这种条件概率的计算方式由指数数量的参数, 其估计实际是不可行的。

朴素贝叶斯法:

- 朴素贝叶斯法为了解决参数过多的问题, 做出了条件独立性的假设:

$$\begin{aligned} & P(X = x|Y = c_k) \\ &= P(x^{(1)} = x^{(1)}, \dots, X^{(n)} = x^{(n)}|Y = c_k) \\ &= \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_k) \end{aligned}$$

即假设用于分类的特征在类确定的条件下是相互独立的。

- 后验概率的计算由贝叶斯定理得出:

$$P(Y = c_k|X = x) = \frac{P(X = x|Y = c_k)P(Y = c_k)}{\sum_k P(X = x|Y = c_k)P(Y = c_k)}$$

代入条件独立性假设可得:

$$P(Y = c_k|X = x) = \frac{P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)}|Y = c_k)}{\sum_{k=1, 2, \dots, K} P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)}|Y = c_k)}$$

进而得到朴素贝叶斯分类器L:

$$y = f(x) = \operatorname{argmax}_{c_k} \frac{P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)}|Y = c_k)}{\sum_k P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)}|Y = c_k)}$$

我们又知道, 对于任意一个数据项或特征, 上式分母都相同, 所以:

$$y = \operatorname{argmax}_{c_k} P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)}|Y = c_k)$$

#### 4.1.2 后验概率最大化的含义

- 这一部分主要介绍选择  $P(Y = c_k|X = x)$  最大的  $c_k$  作为  $x$  的分类结果的合理性证明。
- 假设选择0-1损失函数:

$$L(Y, f(x)) = \begin{cases} 1, Y \neq f(x) \\ 0, Y = f(x) \end{cases}$$

我们可以得到期望风险函数：

$$\begin{aligned} R_{exp}(f) &= E[L(Y, f(X))] \\ &= E_X \sum_{k=1}^K [L(c_k, f(X))] P(c_k|X) \end{aligned}$$

为了使期望风险最小化，只需对  $X = x$  逐个极小化，得到：

$$\begin{aligned} f(x) &= \arg \min_{y \in \mathcal{Y}} \sum_{k=1}^K L(c_k, y) P(c_k|X = x) \\ &= \arg \min_{y \in \mathcal{Y}} \sum_{k=1}^K P(y \neq c_k|X = x) \\ &= \arg \min_{y \in \mathcal{Y}} (1 - P(y = c_k|X = x)) \\ &= \arg \max_{y \in \mathcal{Y}} P(y = c_k|X = x) \end{aligned}$$

通过以上推导我们可以看出，当  $P(y = c_k|X = x)$  取最大时，我们的期望风险将降到最低。这也就是朴素贝叶斯法所采用的原理。

## 4.2 朴素贝叶斯法的参数估计

### 4.2.1 极大似然估计

- 在计算先验概率和条件概率时我们可以应用极大似然估计，计算如下：

先验概率：

$$P(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k)}{N}, k = 1, 2, \dots, K$$

条件概率：

$$\begin{aligned} P(X^{(j)} = a_{jl}|Y = c_k) &= \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k)}{\sum_{i=1}^N I(y_i = c_k)} \\ j &= 1, 2, \dots, n; l = 1, 2, \dots, S_j; k = 1, 2, \dots, K \end{aligned}$$

其中， $x_i^{(j)}$  是第  $i$  个样本的第  $j$  个特征； $a_{jl}$  是第  $j$  个特征可能取的第  $l$  个值； $I$  为指示函数（计数函数）

### 4.2.2 学习与分类算法

1. 计算先验概率和条件概率
2. 对于给定的实例  $x = (x^{(1)}, x^{(2)}, \dots, x^{(n)})^T$ , 计算：

$$P(Y = C_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_k), k = 1, 2, \dots, K$$

3. 确定实例  $x$  的类：

$$y = \arg \max_{c_k} P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_k)$$

### 4.2.3 贝叶斯估计

- 在极大似然估计中，可能会出现所要估计的概率值为0的情况。这时会影响到后验概率的计算结果，使分类产生偏差。这一问题可通过贝叶斯估计解决。
- 贝叶斯估计实际上是在每个频数上都加了一个相同的正数 $\lambda$ ，当 $\lambda = 0$ 时，贝叶斯估计就是极大似然估计。
- 通常我们将 $\lambda$ 取1，此式成为拉普拉斯平滑。并且可知，此式的贝叶斯估计是一种概率分布。
- 条件概率的贝叶斯估计：

$$P_{\lambda}(X^{(j)} = a_{jl} | Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k) + \lambda}{\sum_{i=1}^N I(y_i = c_k) + S_j \lambda}, \lambda \geq 0$$

- 先验概率的贝叶斯估计：

$$P_{\lambda}(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k) + \lambda}{N + K \lambda}$$